


Dekompozice jazyka rizikových faktorů v 10-K výkazech a následná volatilita akciových výnosů

Bakalářský seminář

Vysoká škola ekonomická v Praze

Motivace a dvě protichůdné literatury

Item 1A (Risk Factors) je textová část výročních zpráv veřejně obchodovatelných firem v USA, která je předmětem dvou paralelních literatur, které předpovídají efekty v opačných směrech.



Tato práce odděluje OBJEM a SPECIFIČNOST v jedné regresi a doplňuje třetí kanál: co firma vůči peerům VYNECHÁ.

Co je Item 1A a proč na něm záleží

Struktura výroční zprávy (10-K)

10-K filing (celý dokument)

Item 1A — Risk Factors

Item 7 — MD&A (doplňkový text)

Klíčové vlastnosti části výroční zprávy Item 1A

- Povinná sekce od 2005 (SEC Regulation S-K)
- Popisuje materiální rizika, jimž firma čelí
- Medián ~8 800 slov; rozsah 2 000–40 000
- Firma volí, co uvede a v jakém rozsahu
- Právní safe harbour motivuje boilerplate
 - právníci přidávají standardní formulace
 - firm-specific obsah se zředí

Otázka: nese délka, slovník, nebo to, co firma VYNECHÁ, informaci o budoucí volatilitě?

Hypotézy

H1

OBJEM



Delší Item 1A → vyšší následná
volatilita.

H2

SPECIFIČNOST



Vyšší hustota rizikových slov při
kontrole délky → nižší volatilita.

H3

MLČENÍ



Větší peer-relativní opomenutí
témat → vyšší volatilita.

Druhý stupeň H2: efekt nese LM-Litigious sub-list, nikoli LM-Uncertainty.

Data

535

firem (S&P 1500, nefinanční)

2010–2024


fiskálních let

~5 700

firma-let ($h = 30$ d)

93,5 %

LLM-audit přesnost



Kvalita dat a XBRL tag locking a LLM audit

XBRL tag locking

Problém:

Jeden koncept (např. provozní Cash Flow) může být v XBRL reportován pod různými tagy v různých letech.

Řešení:

1. Equivalence groups — tagy se stejným ekonomickým významem sloučíme (např. NetCashProvided... vs. ...ContinuingOperations).
2. Per-firm tag locking — každou firmu zamkneme na tag, který používá nejčastěji; ostatní = missing.

Výsledek: kompletnost dat 78,9 % → 92,7 %

LLM-assisted quality audit

Cíl:

Ověřit, že HTML parser extrahuje správnou sekci (Item 1A / Item 7) a ne TOC, přílohu či jinou část.

Metoda:

Gemini 2.5 Flash klasifikuje 200 náhodných extrakcí (stratifikovaně 2010–2024) na 5 kritérií: identita sekce, start/end hranice, kvalita, úplnost.

Výsledek: 93,5 % Pass + Minor

Selhání koncentrována v 2010–2012 (nestandardní HTML).

Wilson 95% CI: 89,2–96,2 %. Přístup validace LLM podpořen v Gilardi et al. (2023).

Co měří Litigious a Uncertainty

Loughran & McDonald (2011) — standardní finanční sentiment slovník. Používáme dvě sub-kategorie relevantní pro rizikový jazyk:

LM-Litigious

Právně specifické výrazy:

"litigation", "indemnify", "breach",
"enforcement", "claimant", "arbitration"...

Interpretace:

Standardizovaný safe-harbour boilerplate — právníci přidávají jako ochranu před žalobami. Signál: nízká firm-specificity.

LM-Uncertainty

Modální/hedgingová slova:

"may", "could", "possible", "might",
"approximate", "uncertain", "risk"...

Interpretace:

Hedging neznámého — management signalizuje, že výsledek nelze předpovědět. Obecnější než Litigious.

Kompozitní proměnná:

$$RiskDensity = (n_{unc} + n_{lit}) / Words_{1a}$$

Korelace $UncDensity$ vs. $LitDensity \approx -0,05 \rightarrow$ odlišitelné v regresi.

Metodologie: specifikace modelu

Společný model H1 + H2

$$\ln \sigma_{i,t+1}^H = \alpha + \varphi \cdot \ln \sigma_{i,t}^H + \beta' \cdot X_i^{f,n} + \beta_{len} \cdot \ln(Words_{1a}) + \beta_{ens}^d \cdot RiskDensity + \mu_j + \tau_t + \varepsilon$$

β_{len}

log délka Item 1A

H1 — objem

β_{ens}^d

RiskDensity (LM)

H2 — specifická

$\beta_{un}^c + \beta_{lit}$

Dekompozice LM

Druhý stupeň H2

β_{om}

Omission_{1a} vůči peerům

H3 — strategické mlčení

Závislá proměnná: $sd(\text{denních log-returnů})$ v okně $[\text{filing}+2d, \text{filing}+h]$, annualizováno $\times \sqrt{252}$, v logu.

OLS · FE (odvětví/firma + rok) · SE klastrované dvouvrstvě (firma × rok) · Kontroly: Size, Leverage, ROA, Asset Growth, lagged σ .

Výsledky H1 + H2 a koeficienty napříč horizonty

$$\beta_{len} = +0,121$$


$t = +7,64$ · H1 podpořeno

$$\beta_{dens} = -3,88$$

$t = -2,68$ · H2 podpořeno


$$n = 5\,691$$

firma-let · $h = 30$ d



Pozn.: LitDensity a UncDensity škálovány /10 pro vizuální srovnání. Oba kanály identifikovány současně v jedné regresi.

Dekompozice LM slovníku (druhý stupeň H2)



LM-Litigious

$t = -3,38 \cdot p < 0,001$

Boilerplate (safe-harbour formulace) nese celý negativní efekt specificity.

LM-Uncertainty

$t = -1,01 \cdot p \approx 0,31$


Hedging neznámého nemá samostatnou sílu po kontrole délky a litigious wordingu.

Intuice: trh ignoruje právní boilerplate (opakující se "may be subject to litigation"), ale reaguje na firm-specific obsah zachycený délkou.

Waldův test $\beta_{un}^c = \beta_{lit}$: $z = +1,91$ ($p = 0,056$).

Konstrukce Omission_{1a}

Co firma NEŘEKNE relativně k peerům může informovat o budoucí volatilitě.



Příklad: peer-cell píše 50× „cybersecurity, ransomware“ a focal firma to nezmíní → vysoké Omission_{1a} → vyšší budoucí σ .

Korelace $Omission_{1a}$ vs. $\ln(Words_{1a}) = -0,85 \rightarrow$ nutná kontrola délky v regresi.

Strategické mlčení (H3) — výsledky

Odvětví + rok FE (cross-section)

$$\beta_{om} \approx 0$$

$|t| < 1,1$ na všech horizontech

Stabilní mezifirmní rozdíly v pokrytí $\rightarrow$ nenesou informaci o σ

Firma + rok FE (within-firm)

$$\beta_{om} = +1,345$$

$t = +2,93 \cdot p = 0,003$ ($h = 30$ d)


Meziroční ZMĚNA v opomenutí $\rightarrow$ informace o σ

Proč firma FE mění výsledek?

- Mezi firmami: velké stabilní rozdíly v šíři rizikového profilu (IT firma vs. utilita) — trvale různé Omission $\rightarrow \beta \approx 0$.
- Within-firm: co se změní rok-od-roku v tom, co firma vynechá relativně k vlastnímu průměru — TAM je informace o budoucí σ .

+1 within-firm SD (0,054) $\approx$ +7,3 % na 30denní volatilitě. $n = 4\,630$ firma-let.

T-statistiky napříč horizonty



Pozn.: Vodorovné pásmo $|t| = 2$ odpovídá hladině 5 %.

Pre-COVID vs. COVID

Stejný vzorec v obou podvzorcích (2010–2019 vs. 2020–2024).

Firemní FE

β_{len} přežívá (+0,084; $t = +3,31$); sub-density absorbovány (boilerplate = trvalý firemní rys).

H3 placebo

Náhodné přiřazení do SIC2 buněk $\rightarrow |t| \in [0,54; 0,90]$ vs. reálné $t = +2,93$. Efekt je peer-specifický.

≥ 20 peerů

Velké buňky: $\beta_{\text{om}} = +2,52$ ($t = +3,09$). Signál silnější s přesnějším peer-agregátem.

Závěr a přínos

1

Objem ≠ specifičnost

Oba kanály jsou současně identifikovatelné v jedné regresi. Délka = riziko; boilerplate = šum.

2

Boilerplate, ne hedging

Negativní efekt drží LM-Litigious slovník, ne obecné výrazy nejistoty.

3

MLčení vůči peerům

Co firma neřekne relativně k peerům informuje o budoucí σ (within-firm).

Limity: predikční (nikoli kauzální) čtení · vzorek velkých amerických firem · H3 závisí na volbě peer-benchmarku (SIC2) a v decilech slábne.

Přínos: replikovatelná pipeline (SEC EDGAR XBRL · HTML parser · LM dekompozice · peer-omission konstrukt) — modulární kód pro další výzkum.

Zdroje

Campbell, J. L., Chen, H., Dhaliwal, D. S., Lu, H., & Steele, L. B. (2014).

The information content of mandatory risk factor disclosures in corporate filings. *Review of Accounting Studies*, 19(1), 396–455.

Hope, O.-K., Hu, D., & Lu, H. (2016).

The benefits of specific risk-factor disclosures. *Review of Accounting Studies*, 21(4), 1005–1045.

Loughran, T., & McDonald, B. (2011).

When is a liability not a liability? Textual analysis, dictionaries, and 10-Ks. *The Journal of Finance*, 66(1), 35–65.

Gilardi, F., Alizadeh, M., & Kubli, M. (2023).

ChatGPT outperforms crowd workers for text-annotation tasks. *PNAS*, 120(30), e2305016120.

Děkuji za pozornost

Šimon Slanský · VŠE FIS · 2026